# Poltrona de Dados

MC536

# Olá, Tudo certo?

Somos o grupo Poltrona de Dados



# Tópicos

1 Introdução ao Tema Qual Tema será abordado?

4 Tratamento dos Dados Organização dos dados colhidos

2. Datasets
Datasets utilizados

5. Bancos online
Utilização de bancos em cloud

- 3. Modelos Relacionais e Lógicos Modelos criados
- Queries e Resultados
  Consultas feitas e seus vereditos

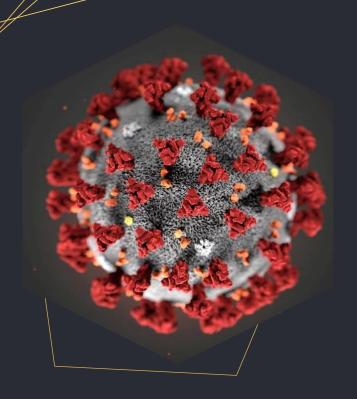


# Introdução ao Tema

Qual Tema será abordado?



### Pandemia COVID-19



Dado o contexto atual da pandemia, achamos relevante abordar um tema relacionado ao coronavírus.

Sendo assim nosso objetivo é relacionar os dados sobre a covid-19 a dados socioeconômicos, educacionais, geográficos, entre outros.



# Datasets

Quais datasets serão utilizados?



### Datasets

World Bank Socio Economics

World Development

COVID19

COVID19 API

World Bank Education
Education

#### COVID-19 Dataset

Nesse dataset, com estrutura hierarquica, temos as seguintes informações agrupadas por país:

- Total de casos;
- Total de mortes;
- Total de recuperados;
- Novos casos;

- Novas mortes;
- Novos Recuperados;
- Data;
- Posição geográfica do país.

```
"Message"; "",
"Global": {
 "NewConfirmed": 443698,
 "TotalConfirmed": 41220369.
  "NewDeaths": 6668,
 "TotalDeaths": 1131337.
 "NewRecovered": 214218.
  "TotalRecovered": 28116565
"Countries": [
    "Country": "Afghanistan",
    "CountryCode": "AF",
    "Slug": "afghanistan",
    "NewConfirmed": 153,
    "TotalConfirmed": 40510,
    "NewDeaths": 2,
    "TotalDeaths": 1501,
   "NewRecovered": 34,
   "TotalRecovered": 33824,
    "Date": "2020-10-22T22:47:30Z",
    "Premium": {}
    "Country": "Albania",
    "CountryCode": "AL",
    "Slug": "albania",
    "NewConfirmed": 297,
    "TotalConfirmed": 17948.
    "NewDeaths": 4,
    "TotalDeaths": 462,
    "NewRecovered": 116.
    "TotalRecovered": 10341.
    "Date": "2020-10-22T22:47:30Z",
    "Premium": {}
```

Brazil 🗸 🛈			
		2011	2012
Adolescent fertility rate (births per 1,000 women ages 15-19)	4	65.5	64.1
Agriculture, forestry, and fishing, value added (% of GDP)	٦	4.3	4.2
Annual freshwater withdrawals, total (% of internal resources)	4		1.3
Births attended by skilled health staff (% of total)	4	99.0	99.0
CO2 emissions (metric tons per capita)	4	2.2	2.4
Contraceptive prevalence, any methods (% of women ages 15-49)	4		
Domestic credit provided by financial sector (% of GDP)	4		
Electric power consumption (kWh per capita)	7	2,430.8	2,501.5
Energy use (kg of oil equivalent per capita)	4	1,367.2	1,413.7
Exports of goods and services (% of GDP)	٦	11.6	11.9
External debt stocks, total (DOD, current US\$)	4	404,046,105,34	440,515,187,63
Fertility rate, total (births per woman)	4	1.8	1.8
Foreign direct investment, net inflows (BoP, current US\$)	4	102,427,229,78	92,568,379,494
Forest area (sq. km)	4	4,974,740.0	4,964,900.0
GDP (current US\$)	4	2,616,200,980,3	2,465,188,674,4

#### World Bank Socio Economics

Dataset tabular contendo diversas informações e indicadores sobre a economia, saúde, aspectos da população em geral, entre outras áreas. É possível traçar uma relação entre os dados contidos neste banco e dados provenientes do dataset referentes ao coronavírus. O banco de dados possui ainda informações de anos diferentes, possibilitando ainda que análises distintas sejam feitas.

### World Bank Education

Nesse dataset, com estrutura tabular, temos diversas informações sobre dados relacionados a educação. A ideia é relacionar como o acesso a educação teve efeito nas medidas tomadas pelos governos e nas consequências da pandemia

	_			
		2017	2018	2019
Adjusted net intake rate to Grade 1 of primary education, gender parity index (GPI)	4	1.0		
Adjusted net intake rate to Grade 1 of primary education, male (%)	4	87.6		
Adult illiterate population, 15+ years, % female	4	50.1	49.8	
Adult illiterate population, 15+ years, both sexes (number)	1	11,276,037.0	11,167,773.0	
Adult illiterate population, 15+ years, female (number)	4	5,644,716.0	5,562,972.0	
Adult illiterate population, 15+ years, male (number)	4	5,631,321.0	5,604,800.0	
Adult literacy rate, population 15+ years, both sexes (%)	4	93.1	93.2	
Adult literacy rate, population 15+ years, female (%)	Y	93.2	93.4	
Adult literacy rate, population 15+ years, gender parity index (GPI)	٦	1.0	1.0	
Adult literacy rate, population 15+ years, male (%)	4	92.9	93.0	
Africa Dataset: Average number of grades per multigrade class in primary schools (number of grades)	7		(m)	

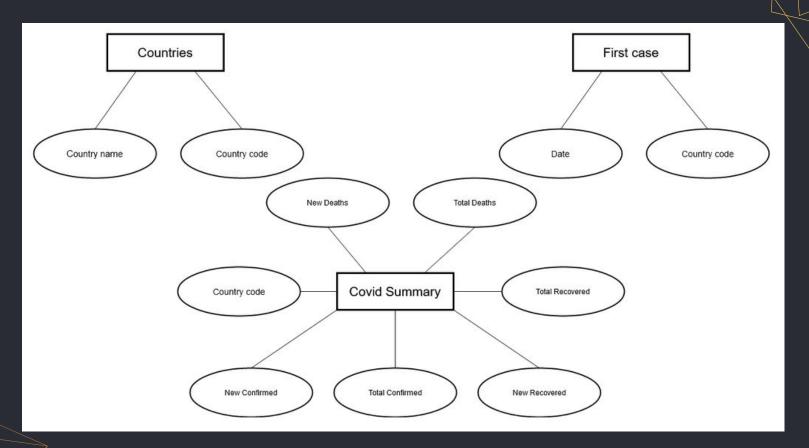


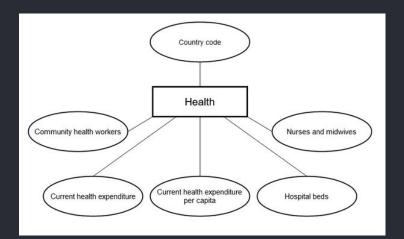
# Modelos Relacionais e Lógicos

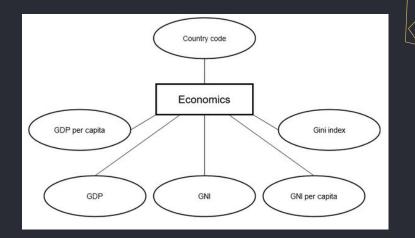
Quais foram os modelos criados?

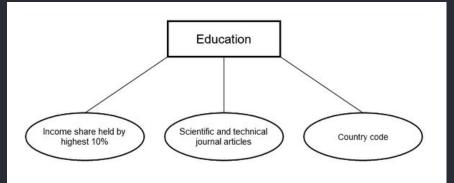


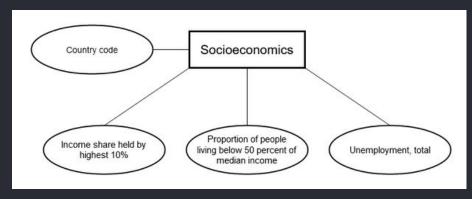
#### Modelos Conceituais

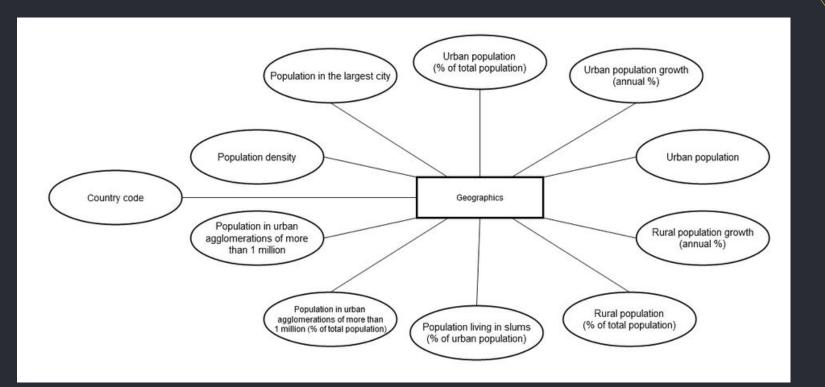




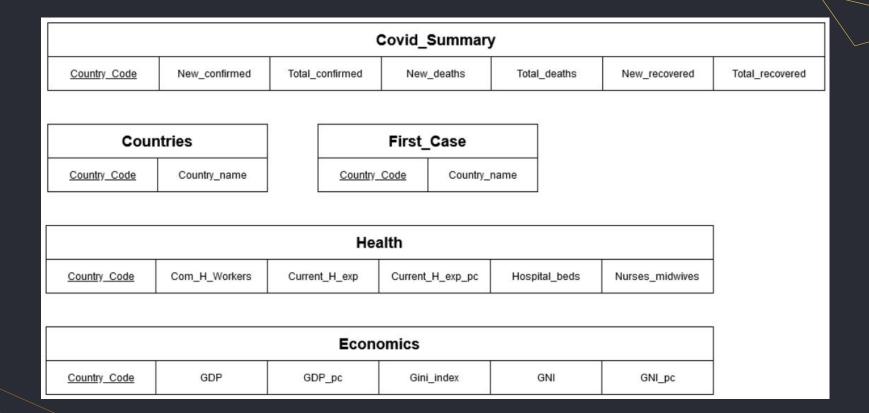








#### Modelos Lógicos



# Socioeconomics Country\_Code Income\_share\_10p living\_below\_50p Unemployment

Education						
Country_Code	Scientific_journals	Research_exp				

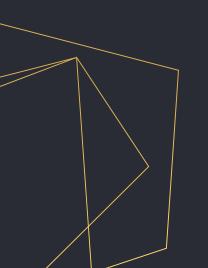
		Geographics				
Country_Code	Urban_Pop	Pop_density	Urban_Pop_p	Urban_Pop_growth_p		

Geographics							
Pop_urban_ag_1mi	Pop_urban_ag_1mi_p	Pop_slums	Rural_Pop_p	Rural_Pop_growth	Pop_largest_city		





Como se deu o tratamento dos dados?



### Dados COVID-19

Utilizando a biblioteca Pandas do Python foi possível fazer o tratamento e limpeza dos dados referentes ao COVID-19 para inseri-los em três tabelas:

#### First case

- countries
- first case

#### Summary

- NewConfirmed •
- NewDeaths
- NewRecovered
- TotalDeaths
- TotalConfirmed
- TotalRecovered

#### Countries

- CountryCode (PK)
   CountryCode (PK)
  - CountryName

### Novas Tabelas

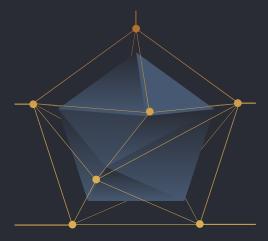
Criadas utilizando dados referentes aos anos de 2017, 2018 e 2019 presentes nos datasets Socio Economics e Education.

#### socioEconomics ANO

Dados socioeconômicos dos países.

economics\_ANO
Dados econômicos dos países

education\_ANO
Indicadores e dados
educacionais



#### health ANO

Indicadores e dados gerais sobre a saúde em cada país.

geographics\_ANO

Dados geográficos dos países



Bancos Online



## Cloud

Visando facilitar o setup do projeto, subimos instâncias de bancos online, para que as queries pudessem ser feitas a partir de um notebook python. Dessa forma, o resultado das queries se deu no formato de estruturas em Python, podemos então cruzar informações armazenadas em datasets de modelos lógicos distintos

### Conexões

Jupyter Notebook

Queries usando bibliotecas em python MongoDB

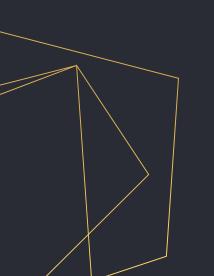
Cluster online utilizando Mongo Atlas Postgres

Instância online do Postgres, utilizando <u>Elephantsql</u>



# Queries e Resultados

Quais queries foram realizadas e quais foram seus resultados?



### Países x Taxa de mortalidade

	Country	alpha_2	Slug	NewConfirmed	TotalConfirmed	NewDeaths	TotalDeaths	NewRecovered	TotalRecovered	first_case	DeathRatio
0	France	FR	france	248	2275677	1	52822	0	167915	2020-01-24T00:00:00Z	0.023212
1	Morocco	MA	morocco	4346	364190	70	5985	4044	314237	2020-03-02T00:00:00Z	0.016434
2	Papua New Guinea	PG	papua- new- guinea	0	669	0	7	0	597	2020-03-20T00:00:00Z	0.010463
3	Portugal	PT	portugal	3384	303846	68	4645	2569	223446	2020-03-02T00:00:00Z	0.015287
4	Andorra	AD	andorra	52	6842	0	76	48	5988	2020-03-02T00:00:00Z	0.011108
		122		0.0	227					m	
186	Bahrain	ВН	bahrain	133	87270	0	341	106	85463	2020-02-24T00:00:00Z	0.003907
187	Saudi Arabia	SA	saudi- arabia	249	357872	12	5919	337	347513	2020-03-02T00:00:00Z	0.016539
188	Republic of Kosovo	хк	kosovo	0	40117	0	1026	0	25586	2020-03-14T00:00:00Z	0.025575
189	Ghana	GH	ghana	0	51667	0	323	0	50547	2020-03-14T00:00:00Z	0.006252
190	Japan	JP	japan	2456	153432	32	2141	1844	127148	2020-01-22T00:00:00Z	0.013954

# Taxa de mortalidade média dos 20 países com maior PIB, 20 países com menor PIB e Geral

```
: df_covid_ratio_pib = df_pib_per_capita.merge(df_covid_ratio, how="inner", on="alpha_2")
: top20_pib_death_ratio = df_covid_ratio_pib.head(20)["DeathRatio"].mean()
    last20_pib_death_ratio = df_covid_ratio_pib.tail(20)["DeathRatio"].mean()
    death_ratio = df_covid_ratio_pib["DeathRatio"].mean()

: print("top20: ", top20_pib_death_ratio)
    print("last20: ", last20_pib_death_ratio)
    print("All: ", death_ratio)

top20: 0.015978299079689017
    last20: 0.02473783886622265
    All: 0.02048843412682874
```

#### Investimento em saúde x Taxa de mortalidade

```
df covid ratio health = df health expenditure per capita.merge(df covid ratio, how="inner", on="alpha 2")
df covid ratio health
 top10 health death ratio = df covid ratio health.head(10)["DeathRatio"].mean()
 last10_health_death_ratio = df_covid_ratio_health.tail(10)["DeathRatio"].mean()
 health death ratio = df covid ratio health["DeathRatio"].mean()
 print("Top 10: ", top10 health death ratio)
 print("Last 10: ", last10 health death ratio)
 print ("All: ", health death ratio)
Top 10: 0.017152070771987122
Last 10: 0.023677886835821914
All: 0.01907830705728344
```

### Investimento em educação x Taxa de mortalidade

```
df_reasearch_death = df_research.merge(df_covid_ratio, how="inner", on="alpha_2")
df_reasearch_death

top_10_research = df_reasearch_death.head(10)["DeathRatio"].mean()
last_10_research = df_reasearch_death.tail(10)["DeathRatio"].mean()
total_research = df_reasearch_death["DeathRatio"].mean()

print("Top_10: ", top_10_research)
print("Last_10: ", last_10_research)
print("All: ", total_research)

Top_10: 0.015175292505589511
Last_10: 0.020476933583673147
All: 0.02030516412427076
```

#### Outras

Foram feitas várias outras queries relacionando dados internos de cada tabela, como, por exemplo:

#### Queries relacionadas a Socio Economics

```
unemployment_query = """
select
cc.country_name,
se.country_code,
cc.alpha_2,
unemployment
from "socioEconomics_{}" se
inner join
country_codes as cc on cc.alpha_3 = se.country_code
where unemployment is not null
order by unemployment desc
"""
```

#### Queries relacionadas a Geografia

```
pop_density_query = """
select
cc.country_name,
e.country_code,
cc.alpha_2,
pop_density
from geographics_{} e
inner join
country_codes as cc on cc.alpha_3 = e.country_code
where pop_density is not null
order by pop_density desc
"""
```

# Obrigado!

Leonardo Livrare - 220120 Pedro Pupo - 204729 Pedro Strambeck - 204759

CREDITS: This presentation template was created by Slidesgo, including icons by Flaticon, infographics & images by Freepik.